

Introdução

Os algoritmos evolutivos visam otimizar um problema dado com a implementação de algoritmos bioinspirados, como por exemplo a seleção natural. Desta forma, neste trabalho, foi feito um algoritmo evolutivo de permutação para encontrar a solução mais ótima para o problema do caixeiro viajante, no qual se deve achar o caminho com a menor distância dado um número de cidades com as distâncias entre elas apresentada.

Metodologia

Foi feito um algoritmo evolutivo de permutação para a solução do problema do caixeiro viajante, usando o método de seleção por torneio com uma taxa de sobrevivência de 50%, usando point crossover para reprodução e taxa de mutação de 5% com método de mudança de ordem. Os valores das taxas foram escolhidos após testes com diferentes combinações.

Foi utilizada a base de dados *Traveling Salesman Problem (TSPLIB Dataset)* que possui 2782 instâncias, o teste do algoritmo foi feito com quatro linhas escolhidas baseados em seus tamanhos, que variam de 20 a 100 cidades.

Instâncias com tamanho entre 20 e 40 foram classificadas como pequenas, 41-70 foram classificadas como médias e 71-100 como grandes. Isso foi feito a fim de medir a performance do algoritmo com tamanhos de instâncias diferentes. Desta forma, foi separado 4 instâncias de cada tamanho para fins de testes.

O número de épocas foi 200 com um tamanho de população de 300.

Resultados

Após a execução do algoritmo nas instâncias pequenas 1, 10, 11 e 17, obteve-se uma média de execução de 9.73 segundos, com tempos de execução de 10.24s, 10.00s, 9.00s e 9.70s respectivamente. Para as instâncias médias 5, 6, 7 e 9 obteve-se uma média de execução de 12.59 segundos, com tempos de execução de 11.23s, 11.76s, 15.79s e 11.60s respectivamente. Para as instâncias grandes 2, 3, 4 e 8 obteve-se uma média de execução de 20.17 segundos, com tempos de execução de 22.26s, 19.22s, 21.54s e 17.68s respectivamente.

A figura 1 mostra um gráfico do tempo de execução pelo número de cidades por instâncias.




Fig 1. Gráfico do tempo de execução por tamanho da instância

Alguns gráficos da evolução do fitness ao longo das gerações, mostrando a evolução individual com o melhor fitness e o fitness médio da população.




Fig 2. Gráfico da evolução do fitness ao longo das gerações para instância 1.




Fig 3. Gráfico da evolução do fitness ao longo das gerações para instância 5.




Fig 4. Gráfico da evolução do fitness ao longo das gerações para instância 2.

Discussão

Pode-se observar que o algoritmo genético converge em todos os casos testados, visto que a linha de melhor fitness tende a se encontrar com o fitness médio da população. Isso significa que um genótipo forte dominou ao longo do tempo.

O tempo de execução do algoritmo cresce linearmente em relação ao número de cidades de certa instância, isso mostra uma complexidade de $O(n)$.

Não foi possível verificar se a solução do algoritmo foi ótima pois o dataset não disponibiliza a melhor rota de cada caso.

Declaração de ética

Neste trabalho, foi usado IA generativa no auxílio no debug do algoritmo evolutivo apenas.