

Introdução

O câncer de mama é uma doença que afeta milhões de mulheres no mundo inteiro, muitas vezes sendo fatal caso seu diagnóstico for tardio.

Desta forma, este trabalho busca produzir um algoritmo de rede neural capaz de identificar células cancerígenas (malignas) e as saudáveis (benignas) usando a base de dados *Breast Cancer Wisconsin (Diagnostic)* com 10 parâmetros diferentes do núcleo das células, sendo eles: raio, textura, perímetro, área, suavidade, compactidade, concavidade, pontos de concavidade, simetria e dimensões fractais.

Metodologia

Foi feita uma arquitetura de rede neural feedforward de uma única camada com função de ativação sigmóide (Fig. 1), com uma taxa de aprendizado de 10^{-2} , este learning rate foi escolhido depois de testes com diferentes learning rates diferentes e análise do gráfico resultante. Além disso, foi utilizado backpropagation (Fig. 2) e métrica de regressão RMSE (Fig. 3). A escolha do RMSE foi devido ao fato de que esta métrica de regressão possui fácil interpretação dos dados e destaca os erros.

A função sigmóide foi escolhida pois se trata de um base de dados binária, ou seja, apenas existem duas classes.

$$\frac{1}{1 + e^{-s}}$$

Fig 1. Função sigmóide

$$2(\hat{y}_i - y_i)\hat{y}_i(1 - \hat{y}_i)x_j$$

Fig 2. Backpropagation aplicado na rede.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Fig 3. Fórmula do RMSE

A base de dados possui total de 569 instâncias, desta forma foi separado 75% (427 instâncias) das instâncias para treino e 25% (142 instâncias) para a realização dos testes. Antes da execução do treinamento, os dados foram embaralhados a fim de ter o dataset de teste com dados aleatórios, assim fazendo com que o aprendizado do algoritmo fosse mais eficiente. Foram feitas 1000 épocas no total.

Ao final do processamento dos dados e a execução dos testes, foram medidos a acurácia global e para cada uma das classes a precisão, recall e F1-score a fim de medir a performance da rede neural.

Resultados

A rede neural obteve um total de 88 verdadeiros negativos, 37 verdadeiros positivos, 1 falso positivo e 16 falsos negativos. Os resultados foram colocados em uma matriz confusão (Fig 4) organizada onde os verdadeiros negativos são as células benignas e os verdadeiros positivos células malignas.

$$\begin{bmatrix} 88 & 1 \\ 16 & 37 \end{bmatrix}$$

Fig 4. Matriz confusão obtida a partir dos resultados

Com os dados obtidos, pôde ser calculada a precisão, recall e F1-Score para cada uma das classes, apresentado na tabela na figura 5. A acurácia global foi de 0,88.

Classe	Precisão	Recall	F1 Score
Benigno	0.85	0.99	0.91
Maligno	0.97	0.70	0.81

Fig 5. Tabela com métricas de classificação

Além destas métricas, um gráfico do erro por épocas foi produzido a fim de analisar a evolução da rede neural ao longo do treino (Fig. 6).



Fig 6. Gráfico do erro pelas épocas.

Discussão

Pode-se chegar a conclusão que a rede neural prevê células benignas de forma excelente, mas células malignas de forma não satisfatória, pois, mesmo tendo uma precisão alta de 0.97 para este tipo de classe, o recall baixo de 0.70 mostra uma grande quantidade de falsos negativos, o que é indesejável numa rede neural que visa a detecção de células cancerígenas. Adicionalmente, a rede neural converge pela análise do gráfico (Fig. 6), ou seja, o erro vai tentando a zero, isso mostra que a rede neural funciona de forma esperada.

Isso pode se dar pelo fato de que a base de dados possui 357 células benignas e 212 células malignas, causando um desbalanceamento no treinamento da rede neural, fazendo com que esta consiga identificar células saudáveis com boa precisão, mas células malignas com baixa precisão devido a falta destes tipos de instância. Adicionalmente, o uso do embaralhamento aleatório dos dados aumenta a chance dos dados terem muito mais instâncias de uma classe do que a outra.

Desta forma, conclui-se que a rede neural é funcional para detectar células benignas mas falha na identificação de células malignas, causado tanto pelo desbalanceamento de dados quanto pela forma de distribuição dos dados de treino e teste.

Assim, pode-se afirmar que o algoritmo pode ser melhorado adicionando mais camadas de neurônios para que os pesos sejam ajustados de forma mais constante, o uso de outro tipo de embaralhamento de dados, buscando um balanceamento entre a quantidade de instâncias das duas classes e o uso de outra base de dados que possuam mais instâncias da classe maligna.

Declaração de ética

Neste trabalho, foi usado IA generativa no auxílio do debug do código da rede neural apenas.